



La fábrica de datos: ETL, CQRS y servicios que trabajan en la sombra

Datos de la actividad

Número actividad	3
Docente	David Aldón Mínguez
Lengua de docencia	Castellano
Agrupación	Individual
Fecha de entrega	11-05-2026

Descripción de la actividad

La Actividad 3 introduce al estudiante en el procesamiento de datos backend mediante la construcción de un flujo ETL y la aplicación del patrón CQRS dentro de un entorno corporativo simulado. El objetivo es comprender cómo se extraen, transforman y cargan datos desde fuentes heterogéneas, y cómo se estructuran comandos y consultas para separar la lógica de escritura y lectura, tal como ocurre en arquitecturas modernas orientadas a la escalabilidad.

A través del caso de DataSphere, el alumnado trabaja con datos simplificados de activos geolocalizados y condiciones asociadas a fenómenos naturales. A partir de ellos, diseña un flujo ETL, implementa un comando de ingestión (versión funcional o dummy) y desarrolla consultas que permiten obtener información relevante para el análisis de exposición al riesgo. Además, se introduce la autenticación servicio-servicio mediante API Keys, reflejando cómo los procesos internos automatizados deben validarse entre sí dentro de un ecosistema distribuido.

La actividad mantiene la independencia técnica entre tareas: el estudiante puede operar sobre bases de datos reales, datos en memoria o implementaciones dummy, siempre que demuestre comprensión de los conceptos clave. Todo el proceso se documenta mediante Git siguiendo buenas prácticas de organización profesional.

En conjunto, esta actividad acerca al estudiante al trabajo con pipelines de datos reales, reforzando la integración entre procesamiento, arquitectura y seguridad dentro del desarrollo backend.

Competencias

COMPETENCIAS (CE / CT)	RESULTADO DE APRENDIZAJE (RA)	INDICADORES DE EVALUACIÓN (IE)
CE2	RA1. Resumir las diferentes tecnologías web y sus interacciones.	IE1. El estudiante identifica los componentes implicados en un proceso de ingestión y procesamiento de datos (entrada, transformación, persistencia y consulta).
CE2, CT3	RA3. Utilizar las técnicas y los procedimientos más adecuados para el diseño de una aplicación web a partir de diferentes fuentes de	IE3. El estudiante diseña un flujo ETL coherente y justifica la separación de responsabilidades a partir de documentación técnica.



COMPETENCIAS (CE / CT)	RESULTADO DE APRENDIZAJE (RA)	INDICADORES DE EVALUACIÓN (IE)
	información.	
CE2	RA4. Analizar la idoneidad de las diferentes tecnologías web y su integración según las necesidades del usuario.	IE4. El estudiante argumenta la elección entre CRUD y CQRS en función del tipo de procesamiento de datos requerido.
CE3	RA7. Analizar y evaluar información desde una amplia gama de fuentes digitales utilizada para dar solución a un problema.	IE7. El estudiante valida el comportamiento del proceso ETL mediante pruebas básicas o evidencias de ejecución y evalúa los resultados obtenidos.
CT4	RA8. Trabajar de forma responsable, ética y de acuerdo con el código deontológico de la profesión.	IE8. El estudiante aplica criterios de seguridad y responsabilidad en procesos de integración servicio–servicio.

Contenido de la actividad

Contenidos	ODS
Diseño de procesos ETL para la ingestión, transformación y carga de datos.	ODS 9 – Industria, innovación e infraestructura Se fomenta la innovación mediante procesos automatizados y el uso eficiente de infraestructuras digitales.
Aplicación del patrón CQRS en sistemas de procesamiento de datos.	ODS 9 – Industria, innovación e infraestructura Se promueve el diseño de arquitecturas escalables y especializadas para lectura y escritura.
Tratamiento de datos geolocalizados y preparación para su análisis posterior.	ODS 13 – Acción por el clima El uso de datos territoriales permite comprender cómo las aplicaciones digitales apoyan el análisis de fenómenos ambientales.
Seguridad en integraciones internas y autenticación servicio–servicio.	ODS 9 – Industria, innovación e infraestructura El diseño de procesos seguros contribuye a infraestructuras digitales fiables y resilientes.

Descripción de las tareas

ETL + CQRS + Procesamiento de Riesgos + Seguridad Servicio–Servicio *Tu primer proceso de ingesta automatizada dentro del ecosistema DataSphere*

✉ Correo de Laura Méndez — Lead Data Engineer (08:14 AM)

Asunto: Bienvenido a DataOps: hoy procesarás tus primeros datos de riesgo

Hola,

En esta actividad vas a unirte por primera vez al equipo de **DataOps**, el área responsable de transformar los datos brutos en información útil para los analistas de riesgos. Nuestro objetivo es ayudarte a entender cómo funciona un **ETL**, cómo aplicamos **CQRS** y cómo los servicios internos se autentican entre sí usando **API Keys**.

Para evitar bloquearte, todas las tareas son **independientes**: puedes trabajar con base de datos o



datos en memoria, y puedes entregar versiones completas o **dummies funcionales** mientras demuestrés comprensión.

Hoy trabajarás con un subconjunto simplificado de nuestro sistema de riesgos naturales.

¡Ánimo!

— Laura

Lead Data Engineer, DataSphere

Herramientas necesarias para completar la actividad

1. Visual Studio / Visual Studio Code

- Para crear la API mínima (.NET 7/8).
- Puedes usar plantillas de Minimal API o controlador clásico.

2. SQL Server Express / LocalDB

- Uso: base de datos local con una tabla Assets.
- Descarga: <https://www.microsoft.com/sql-server/sql-server-downloads>

3. Postman

- Para probar endpoints o, en caso de versión dummy, simular las peticiones.
- Descarga: <https://www.postman.com/downloads/>

4. Git

- Commit atómico, estructura limpia y capturas del historial.
- Descarga: <https://git-scm.com/>

MODELO DE DATOS DE ENTRADA (simple, máximo 2 estructuras)

El equipo te entrega dos ficheros ficticios que representan los datos brutos que llegan a DataSphere (Crea tú mismo estos ficheros en formato .txt, con las columnas indicadas y añade algunas filas con valores):

1. Assets (activos físicos)

- Id
- Name
- Latitude
- Longitude
- RegionCode
- AssetValue (valor económico del activo)

2. AssetConditions (condiciones de exposición por peligro)

- Id
- AssetId
- HazardType (Tornado, Volcano, Hurricane, Rainstorm, Windstorm, Earthquake...)
- SeverityLevel (1–5)
- ProbabilityScore (1–5)

Con solo estas dos tablas, DataSphere puede calcular exposición, filtrar activos por peligros y estimar la severidad geográfica.

TAREA 1 — Diseño del flujo ETL (Extract → Transform → Load)

Reunión con Viktor (Data Architect)

“Antes de programar, tienes que pensar. Un buen ETL empieza siempre por un **diseño claro**.”

✓ Qué debes hacer

Diseña el flujo ETL que transforma los datos brutos (Assets y AssetConditions) en un conjunto de datos limpio y utilizable para análisis.

Debe verse claramente:

- **Extract:** de dónde salen los datos (ficheros, listas, ZIP simbólico, etc.)
- **Transform:** filtrado de condiciones, agrupaciones, cálculo de riesgo, etc.
- **Load:** a una tabla destino o estructura final.

✓ Requisitos obligatorios



- **DIAGRAMA GRÁFICO** en Draw.io / diagrams.net (bloques y flechas, no solo texto).
- Cada bloque debe indicar **qué hace** (“Filtrar severidad ≥ 3 ”, “Unir activos y condiciones”).
- Explicación debajo de la imagen.

 Entregables:

- Diagrama ETL con tu nombre dentro de la imagen
- Captura de los ficheros TXT contruidos con su contenido
- Explicación de cada captura

 Frase sugerida:

“Este flujo representa cómo DataSphere transforma datos brutos en información lista para análisis de riesgos.”

Nota: Piensa en como descomponer el ETL, utiliza el material de la asignatura/videos/internet. ¡Más allá de estas tres acciones, suceden subacciones!

 TAREA 2 — Implementación del ETL (Command CQRS)

Versión base de datos o versión printout — mismas condiciones de corrección

 Reunión con Clara (Senior Data Engineer)

Clara te cuenta:

“Nuestro ETL no necesita ser complejo. Lo importante es demostrar que entiendes cómo se extrae, transforma y carga información”.

 Qué debes hacer

Implementa un pequeño ETL que realice al menos una transformación útil sobre los datos.

Puedes elegir entre dos niveles:

 Versión A — Inserción en base de datos (opcional)

- Lee datos desde fichero
- Filtra, transforma o agrupa (al menos una operación lógica)
- Inserta el resultado en una tabla destino
- Encapsula la lógica en un **Command Handler** (CQRS)

Ejemplos aceptables:

- Solo insertar activos con $\text{SeverityLevel} \geq 3$
- Calcular un “RiskScore” simple ($\text{SeverityLevel} * \text{ProbabilityScore}$)
- Unir activos + condiciones y cargar un dataset limpio

 Capturas necesarias:

- Código del Command
- Tabla destino con datos/ Listas en memoria
- Arquitectura diseñada
- Program.cs
- Extracción de los Datos del TXT
- Tu nombre visible
- Explicación en cada captura

 Versión B — Solo printout (igual valoración)

Si no quieres usar base de datos como almacenamiento, implementa el ETL haciendo print de los datos leídos y procesados.

 Frase sugerida:

“Este comando representa el proceso de ingesta de datos brutos dentro del pipeline de DataSphere.”



■ TAREA 3 — Queries (Lectura CQRS)

Datos desde BD o desde memoria — mismo valor de evaluación

■ Reunión con Pablo (Data Analyst)

“Queremos ver si puedes consultar los datos y responder preguntas típicas de exposición al riesgo.”

✓ Qué debes hacer

Crea al menos 2 Queries que respondan preguntas de análisis, como:

- activos con severidad alta para tornados,
- valor total expuesto en una región,
- activos con varias condiciones.

Dos versiones aceptadas:

● Versión A — Query desde la base de datos

- Realizas una consulta LINQ/SQL sobre la tabla destino
- Devuelves una lista o un valor agregado

● Versión B — Query en memoria

- Usas una lista con datos hardcoded
- Devuelves un resultado coherente

✓ Requisitos

- Separar la Query en una clase o handler
- Incluir una explicación funcional
- Código claro y visible

📁 Entregables:

- Código de la Query
- Diseño del patron/Arquitectura
- DI (Inyección de dependencias visible)
- Resultado (print o captura debug)
- Tu nombre visible

📝 Frase sugerida:

“Esta Query permite responder una pregunta de exposición al riesgo dentro del sistema DataSphere.”

■ TAREA 4 — Seguridad servicio–servicio (API Key)

Debe verse un 200 y un 400/401 — implementación real o dummy

■ Email de Samir (Security Engineer)

“El ETL no es un usuario humano; no hace login. Se identifica con una **service account** mediante una **API Key**.”

✓ Qué debes hacer

Simula que tu ETL envía una notificación a un endpoint protegido por API Key.

- Endpoint en una API (Minimal API vale)
- Revisar header x-api-key
- Si es incorrecto → 400/401
- Si es correcto → 200
- Postman debe mostrar al menos ambas llamadas

📁 Entregables:

- Captura Postman: error → éxito
- Código del endpoint
- Tu nombre visible

📝 Frase sugerida:

“Este endpoint simula cómo un servicio ETL se autentica mediante API Key dentro de DataSphere.”

Nota: Piensa en detectar algún caso no mencionado

■ ENTREGABLE FINAL (PDF)

1. Diagrama ETL + explicación
2. Command ETL (BD o print)
3. Queries (BD o memoria)
4. API Key tests en Postman

Evaluación

Criterio	Peso
1. Diseño del flujo ETL	25%
2. Command ETL (BD o print)	25%
3. Queries CQRS (BD o memoria)	25%
4. Seguridad service-service (API Key)	25%

Cada criterio corresponde a un **Resultado de Aprendizaje (RA)** del plan docente.
Cada criterio tiene **4 niveles de logro** equivalentes a la rúbrica institucional.
Cada criterio vale **25% de la actividad**.

■ 1. Diseño del flujo ETL (25%)

RA1. Resumir las diferentes tecnologías web y sus interacciones

IE1. El estudiante identifica los componentes implicados en un proceso de ingestión y procesamiento de datos.

RA3. Utilizar técnicas y procedimientos adecuados para el diseño de aplicaciones web

IE3. El estudiante diseña un flujo ETL coherente y justifica la separación de responsabilidades.

Nivel	Qué debe verse
0–4.9	No se presenta un diagrama ETL o el esquema no distingue claramente las fases de extracción, transformación y carga. No se identifican los componentes del proceso de datos.
5–6.9	Diagrama básico del flujo ETL donde se reconocen las fases del proceso de datos con poca profundidad, aunque con organización o explicación limitada.
7–8.9	Diagrama claro que representa las fases de Extract–Transform–Load en profundidad , identificando los componentes del flujo de datos y explicando de forma clara la separación de responsabilidades y la toma de decisiones.
9–10	Diagrama completo del proceso ETL donde se identifican claramente entrada de datos, transformación, persistencia y consulta , con una explicación que justifica la organización del flujo y la separación de responsabilidades. Se pueden



Nivel	Qué debe verse
	observar algún step no mencionado

■ 2. Command ETL (25%)

RA3. Diseñar soluciones técnicas adecuadas para el procesamiento de datos

IE3. Diseña un flujo ETL coherente y justifica las decisiones técnicas.

RA7. Analizar y evaluar información para resolver un problema

IE7. Valida el comportamiento del proceso ETL mediante pruebas o evidencias de ejecución.

Nivel	Qué debe verse
0–4.9	No se implementa el proceso ETL o el código no refleja las fases de extracción, transformación y carga. Y no se justifica
5–6.9	Implementación simplificada del ETL (por ejemplo mediante prints o simulaciones), con explicación básica del proceso. Donde se justifica cada una de las acciones de forma básica
7–8.9	Implementación funcional del proceso ETL encapsulado en un Command o estructura similar, con transformación de datos y evidencias de ejecución junto con una buena explicación de que es lo que se está haciendo.
9–10	Implementación clara del proceso ETL con separación de responsabilidades, transformación coherente de datos y evidencias o pruebas que validan el funcionamiento del flujo junto con la explicación de alto nivel

■ 3. Queries CQRS (25%)

RA4. Analizar la idoneidad de las tecnologías web según las necesidades del usuario

IE4. Argumenta la elección entre CRUD y CQRS según el tipo de procesamiento de datos.

RA7. Analizar y evaluar información desde fuentes digitales

IE7. Valida el comportamiento del sistema mediante evidencias o pruebas.

Nivel	Qué debe verse
0–4.9	No se implementan queries o no se relacionan con el dominio del sistema ni con el procesamiento de datos. Se observa un bajo nivel de justificación
5–6.9	Queries simplificadas que muestran la estructura de consultas, con explicación básica de su propósito.
7–8.9	Queries funcionales (en base de datos o memoria) que responden a preguntas del dominio y evidencian la separación entre comandos y consultas. Junto con un buen nivel de justificación
9–10	Implementación clara de consultas coherentes con el dominio y explicación de la elección de CQRS frente a CRUD según las necesidades del procesamiento de datos.

■ 4. Seguridad API Key (25%)

RA8. Trabajar de forma responsable y segura en sistemas web

IE8. Aplica criterios de seguridad y responsabilidad en procesos de integración servicio–servicio.



RA7. Analizar y evaluar información para validar el funcionamiento del sistema

IE7. Valida el comportamiento mediante pruebas o evidencias.

Nivel	Qué debe verse
0–4.9	No se aplica ningún mecanismo de seguridad o la integración entre servicios no está definida.
5–6.9	Implementación básica de validación mediante API Key , con explicación básica del mecanismo.
7–8.9	Endpoint protegido mediante API Key o mecanismo equivalente, con evidencia de su funcionamiento en pruebas o capturas.
9–10	Integración servicio–servicio protegida mediante API Key con evidencias claras de validación (por ejemplo respuestas 401/403 → 200), mostrando comprensión de la seguridad en comunicación entre servicios. Junto con un alto nivel de comprensión en la justificación.



Fuentes de información

Libros

- **Fowler, M. (2012). *Patterns of Enterprise Application Architecture*. Addison-Wesley.**
→ Referente para comprender CQRS, separación de comandos y consultas, y arquitectura de datos.
- **Kleppmann, M. (2017). *Designing Data-Intensive Applications*. O'Reilly Media.**
→ Excelente para entender procesos ETL, flujos de datos, consistencia y sistemas distribuidos.
- **Larman, C. (2004). *Applying UML and Patterns*. Prentice Hall.**
→ Útil para la representación visual de procesos ETL y diseño de componentes.

Recursos prácticos

- Microsoft. “What is an ETL Process?”
<https://learn.microsoft.com>
- Microsoft. “Introduction to CQRS”
<https://learn.microsoft.com>
- OWASP. “API Security Top 10”
<https://owasp.org>

Herramientas

- **SQL Server Express / LocalDB** — motor de base de datos gratuito.
- **draw.io (diagrams.net)** — diseño del flujo ETL.
- **Postman** — pruebas de endpoints.
- **Visual Studio / VS Code** — implementación.
- **Git** — control de versiones.

