

UNIVERSITAT Carlemany

Trabajo Final de Grado (TFB) Desarrollar un entorno escalable (pipeline geoespacial) para imágenes Sentinel-2, diseñado para integrar y ejecutar un modelo de Machine Learning

Autor: Antonio López **Fase:** Entrega 2 - Metodología y Desarrollo del Proyecto **Fecha:** Julio 2026

Página web del proyecto: tonilogar.github.io/tfb **Repositorio y control de versiones:** GitHub - Master Roadmap

Resumen con palabras clave

El presente Trabajo Final de Batxelor (TFB) tiene como objetivo principal el desarrollo de una infraestructura Web GIS escalable y agnóstica (pipeline geoespacial) diseñada para procesar datos satelitales del programa Copernicus y permitir la integración de modelos de Machine Learning[cite: 1]. Para validar empíricamente esta arquitectura desacoplada, se aborda como caso de estudio práctico la clasificación errónea de nubes y nieve por parte del algoritmo estándar Sen2Cor en zonas de alta montaña, así como su confusión con sombras y masas de agua[cite: 1]. Como solución a esta deficiencia, se ha implementado y ejecutado sobre el nuevo pipeline un modelo de aprendizaje profundo (Deep Learning) utilizando la red neuronal convolucional U-Net, enfocado en la región de Cataluña (España)[cite: 1]. La orquestación abarca la descarga automatizada de gránulos Sentinel-2, la edición y clasificación manual de máscaras para el entrenamiento, y el diseño del propio modelo[cite: 1]. El sistema obtiene un tensor de segmentación de 6 Clases Maestras: Descarte, Suelo Útil, Nube, Sombra de Nube, Nieve y Masas de Agua[cite: 1]. El resultado se desplegará en una infraestructura Serverless, demostrando que esta arquitectura modular sirve de base para resolver distintas problemáticas geoespaciales de Observación de la Tierra[cite: 1].

Palabras clave: Deep Learning, Sentinel-2, Segmentación Semántica, U-Net, Observación de la Tierra, Copernicus[cite: 1].

Glosario de Términos

Para facilitar la lectura a evaluadores y personas no especialistas en Sistemas de Información Geográfica (GIS), se definen los siguientes términos clave utilizados en este documento:

- **Sentinel-2:** Misión de satélites ópticos de alta resolución de la constelación Copernicus[cite: 1].
- **Sen2Cor:** Software de la Agencia Espacial Europea (ESA) para la corrección atmosférica[cite: 1].
- **Tiling:** Técnica geoespacial que consiste en fragmentar imágenes satelitales en cuadrículas menores para su procesamiento en memoria RAM[cite: 1].
- **OOM (Out of Memory):** Colapso del sistema por saturación de la memoria gráfica al procesar tensores masivos[cite: 1].
- **COG (Cloud Optimized GeoTIFF):** Formato de imagen satelital optimizado para ser consultado de forma rápida en la nube[cite: 1].
- **PMTiles:** Formato de archivo diseñado para almacenar teselas geoespaciales en la nube de forma estática[cite: 1].
- **U-Net:** Arquitectura de red neuronal convolucional diseñada para la segmentación semántica de imágenes[cite: 1].
- **Ground Truth (Verdad Terrestre):** El patrón o mapa de referencia auditado que se usa para entrenar y evaluar el modelo[cite: 1].

- **L1C/L2A:** Niveles de procesamiento satelital. L1C es la imagen cruda (Top of Atmosphere) y L2A incluye corrección atmosférica[cite: 1].
 - **IoU (Intersection over Union):** Métrica matemática estricta utilizada para evaluar el acierto espacial al predecir la forma de un objeto[cite: 1].
 - **Recall (Exhaustividad):** Métrica que mide la capacidad del modelo predictivo para encontrar y señalar todas las instancias reales de una clase[cite: 1].
 - **NDSI (Normalized Difference Snow Index):** Índice matemático que resalta la reflectancia de la nieve frente a las nubes basándose en la radiación infrarroja[cite: 1].
-

1. Introducción

El programa Copernicus, de la Agencia Espacial Europea (ESA) y la Unión Europea, representa actualmente uno de los mayores esfuerzos tecnológicos para la observación de la Tierra[cite: 1]. Sentinel-2 es una misión fundamental dentro de esta constelación, compuesta por dos satélites gemelos (Sentinel-2A y Sentinel-2B) que proporcionan imágenes ópticas multiespectrales de alta resolución[cite: 1]. Las capacidades técnicas de esta misión abarcan desde el espectro visible (RGB) hasta el infrarrojo cercano (NIR) y de onda corta (SWIR)[cite: 1]. Su resolución espacial alcanza los 10 metros por píxel en las bandas principales, 20 metros en las bandas infrarrojas y 60 metros para correcciones atmosféricas[cite: 1]. Gracias al desfase orbital de sus dos satélites, ofrece una resolución temporal de 5 días[cite: 1]. Los datos que estos satélites envían son fundamentales para el análisis de series temporales, permitiendo el seguimiento continuo de fenómenos globales como la agricultura de precisión y la evaluación del impacto de desastres naturales[cite: 1].

2. Justificación

La clasificación algorítmica de píxeles en imágenes satelitales presenta un desafío técnico de primer nivel debido a la complejidad atmosférica y radiométrica[cite: 1]. Para la generación de productos de Nivel-2A en la constelación Sentinel-2, la ESA emplea el procesador estándar Sen2Cor[cite: 1]. Como subproducto de esta corrección, Sen2Cor genera un mapa de clasificación de escena (Scene Classification o SCL) basado en árboles de decisión y umbrales radiométricos fijos[cite: 1].

A pesar de su adopción global, la literatura científica y la observación empírica demuestran que Sen2Cor sufre predicciones erróneas ante geografías orográficamente complejas y heterogéneas, como es el caso de Cataluña[cite: 1]. Al basarse en umbrales empíricos, Sen2Cor opera a nivel de píxel individual; esta carencia metodológica le impide interpretar el contexto espacial, provocando confusión sistemática entre elementos con firmas espectrales similares (nieve y nubes gruesas) o morfologías oscuras (sombras topográficas y sombras de nubes)[cite: 1].

Frente a esta problemática, la investigación reciente evidencia que los modelos de Deep Learning superan significativamente a los algoritmos tradicionales[cite: 1]. Las Redes Neuronales Convolucionales (CNN) logran extraer características espaciales y texturas inalcanzables para los métodos basados puramente en umbrales[cite: 1].

Descarte Arquitectónico del Modelo Digital de Elevaciones (DEM): Durante el diseño de la arquitectura, se valoró inyectar un DEM para proveer a la red de un contexto topográfico que discriminara la nieve (altas cotas) de las nubes[cite: 1]. Sin embargo, se tomó la decisión técnica de descartar su uso, basándose en la física espectral: las bandas infrarrojas de onda corta (SWIR: B11 y B12) resuelven este problema mediante termodinámica[cite: 1]. Las nubes reflejan la radiación SWIR, mientras que la nieve la absorbe masivamente, mostrándose oscura[cite: 1]. Algoritmos consolidados del estado del arte prescinden totalmente de modelos topográficos, basando su precisión en el cálculo

de índices como el NDSI[cite: 1]. Esta decisión evita una sobrecarga innecesaria en la ingeniería de datos, confiando la discriminación a la firma espectral de las bandas físicas[cite: 1].

3. Contextualización del trabajo

Para comprender el alcance del problema, es imperativo analizar dónde disminuye la precisión de Sen2Cor en la práctica[cite: 1]. La algoritmia clásica muestra deficiencias críticas en ecosistemas geográficamente heterogéneos, dando lugar a tres anomalías principales[cite: 1]:

1. **Ambigüedad espectral de la Nieve:** Sen2Cor tiende a confundir sistemáticamente la firma espectral altamente reflectiva de la nieve de alta montaña con los frentes de nubes gruesas[cite: 1].
2. **Falsos positivos por Sombras Topográficas:** El algoritmo es incapaz de discriminar radiométricamente la sombra oscura natural que proyecta el relieve escarpado (sombra orográfica) frente a la sombra de una nube sobre un valle, provocando cortes abruptos[cite: 1]. *(Nota: Tras culminar el entrenamiento basado exclusivamente en espectrometría, se ha constatado que el modelo sigue sufriendo confusión ante la orografía extrema, estableciendo como línea de investigación futura ineludible la fusión temprana de datos multiespectrales con modelos topográficos)*[cite: 1].
3. **Anomalías de absorción en Superficies Hídricas:** Las grandes masas de agua profunda, que absorben fuertemente la radiación infrarroja, son diagnosticadas erróneamente como sombras de nubes (clase 3) o píxeles oscuros (clase 2)[cite: 1]. Paralelamente, los campos con alta saturación hídrica (como los arrozales del Delta del Ebro) son clasificados con frecuencia como masas de agua puras[cite: 1].

4. Objetivos generales y específicos

4.1. Objetivo general

Desarrollar e implementar una infraestructura Web GIS escalable y desacoplada (pipeline geoespacial) diseñada para automatizar la ingesta, inferencia y visualización de datos de observación de la Tierra[cite: 1]. El propósito es construir una arquitectura base que, siendo agnóstica al proveedor de infraestructura, permita la integración modular de modelos de Deep Learning orientados a la segmentación semántica[cite: 1]. Para validar empíricamente este sistema, se presenta como caso de estudio la integración de una red neuronal U-Net específica para la detección de nubes sobre Cataluña[cite: 1].

4.2. Objetivos específicos

1. **Construir una infraestructura de datos replicable (Pipeline ETL):** Desarrollar un flujo automatizado de extracción, transformación y carga que abarque la descarga de datos satelitales (Nivel 1C y 2A) y la edición manual de máscaras para construir una Verdad Terrestre (Ground Truth) rigurosa[cite: 1].
2. **Entrenar y evaluar una arquitectura U-Net:** Diseñar, entrenar y validar una red neuronal convolucional orientada a la segmentación semántica en la región de Cataluña (órbitas relativas R008 y R051 de Sentinel-2)[cite: 1].
3. **Superar métricamente al estándar Sen2Cor:** Mitigar las anomalías de clasificación mediante un análisis comparativo evaluando métricas técnicas rigurosas (*Recall* e *Intersection over Union*) frente a las clasificaciones generadas por la ESA[cite: 1].
4. **Desarrollar la plataforma Web GIS:** Construir la infraestructura visual (Frontend) integrando librerías modernas (MapLibre GL JS y Svelte) para la cartografía bidimensional (2D) y servir las inferencias en formatos optimizados (Cloud Optimized GeoTIFF o PMTiles)[cite: 1].

5. Marco teórico y conceptos clave

5.1. Datos espaciales: Sentinel-2 y el espectro electromagnético

Para optimizar la capacidad de discriminación del modelo, se procesa un tensor multiespectral estructurado en 7 canales simultáneos[cite: 1]:

- **Espectro visible (Bandas 2, 3 y 4):** Azul, verde y rojo[cite: 1]. Capturan texturas, colores naturales y sombras topográficas[cite: 1].
- **Infrarrojo Cercano o NIR (Banda 8):** Crítico para identificar vegetación (alta reflectancia) y cuerpos de agua (fuerte absorción)[cite: 1].
- **Infrarrojo de Onda Corta o SWIR (Bandas 11 y 12):** Fundamental para resolver la ambigüedad espectral de la nieve[cite: 1]. Físicamente, las nubes presentan alta reflectancia, mientras que la nieve lo absorbe fuertemente[cite: 1].
- **NDSI (Normalized Difference Snow Index):** Índice matemático pre-calculado derivado de las bandas Verde y SWIR[cite: 1]. Funciona como un canal adicional que inyecta conocimiento físico explícito sobre la nieve[cite: 1].

5.2. Inteligencia Artificial: La Arquitectura U-Net

Frente a la ceguera espacial de los algoritmos paramétricos tradicionales que evalúan el terreno píxel a píxel, este proyecto fundamenta su avance en la visión artificial (Computer Vision) mediante la arquitectura convolucional U-Net, implementada desde cero (*from scratch*) en PyTorch[cite: 1].

5.2.1. Teoría de Funcionamiento

La U-Net (Ronneberger, Fischer y Brox, 2015) predice la probabilidad de pertenencia a una clase para cada píxel de forma individual[cite: 1]. Consta de tres mecanismos[cite: 1]:

1. **El Encoder (Ruta de Compresión):** Aplica filtros matemáticos reduciendo la resolución pero ganando comprensión de patrones[cite: 1]. Conceptualmente, aprende el "QUÉ" (características abstractas que diferencian las coberturas)[cite: 1].
2. **El Decoder (Ruta de Expansión):** Toma la información comprimida y la reescala progresivamente para proyectarla en el terreno[cite: 1]. Determina el "DÓNDE" (ubicación geográfica)[cite: 1].
3. **Las Skip Connections (Puentes de detalle):** Conectan capas iniciales con las finales de reconstrucción para rescatar los detalles nítidos originales, evitando la pérdida de resolución en las fronteras de los objetos[cite: 1].

5.2.2. Diseño Arquitectónico y Estructura de Datos (Data Shapes)

- **Inferencia:** El modelo procesa un tensor multiespectral de 7 canales[cite: 1]. El Decoder genera un tensor de salida de 6 canales (logits por Clase Maestra)[cite: 1]. La función `Softmax` evalúa qué clase tiene la probabilidad máxima, reduciendo la dimensionalidad a una matriz espacial 2D final con valores del 0 al 5[cite: 1].
- **Entradas (Inputs - X):** Su estructura es `(N, 7, 512, 512)` [cite: 1]. Los tensores se guardan en disco en formato `Float16` para optimizar almacenamiento y velocidad de lectura, pero son casteados a `Float32` antes de entrar a la red para evitar la inestabilidad numérica (desvanecimiento del gradiente) durante el entrenamiento[cite: 1].
- **Salidas (Outputs - Y_pred):** Su estructura es `(N, 6, 512, 512)` [cite: 1].

5.2.3. Justificación de la implementación "From Scratch" frente a redes pre-entrenadas

Se tomó la decisión de implementar la U-Net de forma nativa por las siguientes divergencias[cite: 1]:

- **Incompatibilidad de Entradas:** Nuestra arquitectura exige una topología de 7 canales[cite: 1]. Modificar la capa de entrada de un modelo genérico (diseñado para 3 o 13 canales) invalida los pesos transferidos[cite: 1].
- **Incompatibilidad de Salidas:** Las redes pre-entrenadas suelen devolver máscaras binarias[cite: 1]. Rediseñar simultáneamente las capas de entrada y salida descontextualiza los pesos intermedios[cite: 1].
- **Abundancia de Datos y Sesgo Geográfico:** Iniciar el entrenamiento con los pesos aleatorios inicializados desde cero, utilizando el dataset curado de Cataluña, asegura que el modelo extraiga los patrones orográficos reales, evitando heredar sesgos de modelos globales[cite: 1].

5.2.4. Líneas de Evolución Algorítmica (Trabajo Futuro)

Para maximizar la precisión, se identifican tres vectores de evolución[cite: 1]:

1. **ResUNet:** Integración de bloques residuales para entrenar redes topológicamente más profundas[cite: 1].
2. **Attention U-Net:** Introducción de puertas de atención para suprimir matemáticamente la información redundante del fondo[cite: 1].
3. **Vision Transformers (ViT):** Transición a modelos híbridos para evaluar el contexto espacial global de la imagen desde las etapas iniciales[cite: 1].

6. Metodología aplicada

6.1. Instrumentos

- **Fuente de observación:** Satélite Sentinel-2 (Nivel L1C y L2A)[cite: 1].
- **Pipeline ETL y Entrenamiento:** Estación de trabajo con aceleración hardware GPU (CUDA) [cite: 1].
- **Edición visual:** Software de edición gráfica GIMP[cite: 1].
- **Modelado:** Framework PyTorch[cite: 1].
- **Frontend Web:** Framework Svelte y motor cartográfico MapLibre GL JS[cite: 1].

6.2. Materiales (Dataset y Reducción de Dimensionalidad)

El conjunto de datos consta de 40 gránulos satelitales seleccionados estratégicamente (30 para entrenamiento/validación y 10 aislados estrictamente para Test Ciego)[cite: 1]. Para optimizar el espacio latente, el pipeline colapsa las 12 clases nativas de Sen2Cor en **6 Clases Maestras** operativas[cite: 1]:

- **Clase 0:** Descarte / No Data (Ignorada en el entrenamiento mediante `ignore_index=0`)[cite: 1].
- **Clase 1:** Suelo Útil / Vegetación[cite: 1].
- **Clase 2:** Nube[cite: 1].
- **Clase 3:** Sombra de Nube[cite: 1].
- **Clase 4:** Nieve[cite: 1].
- **Clase 5:** Masas de Agua[cite: 1].

6.3. Recursos e infraestructura

El acceso automatizado se realiza mediante el protocolo OData de la API del Copernicus Data Space Ecosystem (CDSE), garantizando la descarga ininterrumpida de imágenes crudas completas en lugar de mosaicos fragmentados[cite: 1]. El almacenamiento intermedio requirió discos de estado sólido de alta capacidad para albergar los volúmenes tensoriales generados durante la fase de *tiling*[cite: 1].

6.4. Metodología de evaluación

Bajo ningún concepto se evalúa el rendimiento del modelo contra las máscaras originales de Sen2Cor, ya que se incurriría en una paradoja estadística donde la IA sería penalizada por corregir los fallos históricos de la ESA[cite: 1]. La evaluación se realiza de manera aislada contra un conjunto de *Test* cuya Verdad Terrestre ha sido auditada exhaustivamente por intervención humana, utilizando métricas de Intersection over Union (IoU) y Recall[cite: 1].

7. Desarrollo viable y sostenible

7.1. Temporalización e hitos

El proyecto operó bajo metodologías ágiles, abarcando desde la extracción vía API hasta la materialización de un Web GIS integral, conjugando Ingeniería de Datos, Machine Learning y DevOps[cite: 1].

7.2. Alineación con los ODS y Códigos UNESCO

- **Códigos UNESCO:** 1207.94 (Aprendizaje automático), 1203.93 (Cloud Computing) y 1203.96 (Bases de Datos)[cite: 1].
- **ODS:** ODS 9 (Industria, Innovación e Infraestructura) mediante la construcción tecnológica geoespacial y ODS 13 (Acción por el clima) al proveer datos veraces para la monitorización de recursos hídricos[cite: 1].

7.3. Condicionantes ambientales, sociales y económicos

Se aplicaron técnicas de *Green Computing* como el *Void Filtering*, descartando en memoria los cuadrantes satelitales vacíos u oceánicos antes del entrenamiento para reducir masivamente el consumo energético de la GPU[cite: 1]. Todo el ecosistema de herramientas utilizado se apoya en filosofía *Open Source* y formatos de almacenamiento *Cloud-Native* de bajo coste[cite: 1].

8. Proceso y resultados

8.1. Criterios de Selección del Conjunto de Datos (Fase 0)

La selección de los 40 gránulos persiguió maximizar la variabilidad espectral, enfocándose en *Hard Negatives*[cite: 1]:

- **Pirineos (Nieve y nubes):** Escenas invernales donde convergen formaciones nubosas bajas y cumbres nevadas[cite: 1].
- **Llanura Central (Nieblas y cirros):** Situaciones de niebla densa y cirros finos estivales[cite: 1].
- **Costa y Urbano (Falsos positivos brillantes):** Zonas industriales de alta reflectancia[cite: 1].
- **Delta del Ebro (Extremos hídricos):** Campos inundados susceptibles de provocar reflejos especulares (*Sun Glint*)[cite: 1].

8.2. Ingesta de Datos e Ingeniería ETL (Fase 1)

Se desarrolló un orquestador mediante la API OData de CDSE para evadir las colisiones poligonales del protocolo STAC[cite: 1]. Este script asíncrono descarga el producto L1C y L2A, extrayendo y aislando estrictamente las 6 bandas espectrales necesarias[cite: 1].

8.3. Auditoría Visual y Verdad Terrestre (Fase 2)

Para posibilitar la corrección visual de los ficheros radiométricos, se diseñó una arquitectura puente (*Encode/Decode*) [cite: 1]. Un algoritmo empaqueta las bandas en un lienzo RGB multicapa (*GeoTIFF*) [cite: 1]. Tras la auditoría visual mediante un software de edición (GIMP), un script decodificador extrae el mapa cromático, mapeando los colores nuevamente a valores matemáticos (0-5) e inyectando las coordenadas geográficas originales inalteradas [cite: 1]. Esta salida curada constituye la Verdad Terrestre inquebrantable [cite: 1].

8.4. Ingeniería de Datos, Tiling y Void Filtering (Fase 3)

El *pipeline* alinea espacialmente las bandas de 20m a 10m mediante interpolación bilineal y pre-calcula el índice NDSI [cite: 1]. Posteriormente, ejecuta un algoritmo de *Tiling* que segmenta la imagen de 10980×10980 en matrices de 512×512 [cite: 1]. El filtro de relevancia descarta automáticamente cualquier tensor cuya área nula supere el 90%, optimizando la memoria y acelerando el aprendizaje posterior [cite: 1].

8.5. Modelado y Entrenamiento (Fase 4)

La U-Net se implementó instanciando `CrossEntropyLoss(ignore_index=0)` [cite: 1]. Los tensores espaciales almacenados en disco en `Float16` se inflan dinámicamente a `Float32` al cargarse en la memoria gráfica, previniendo el desvanecimiento de los gradientes matemáticos microscópicos durante el proceso de retropropagación a lo largo de las épocas de entrenamiento [cite: 1].

8.6. Inferencia Masiva y Evaluación (Fase 5)

La evaluación empírica sobre los 10 gránulos de Test (sumando más de 1.100 millones de píxeles) arrojó resultados determinantes [cite: 1]:

Clase Geográfica	IoU (%)	Precisión (%)	Recall (%)	F1-Score (%)
Suelo (1)	90.94%	95.17%	95.35%	95.26%
Nube (2)	80.43%	90.07%	88.26%	89.16%
Sombra Nube (3)	46.96%	64.03%	63.78%	63.90%
Nieve (4)	84.64%	89.73%	93.72%	91.68%
Masas de Agua (5)	86.79%	89.54%	96.57%	92.93%

El modelo resuelve de forma implacable la detección de nieve y controla exitosamente los destellos hídricos especulares, aunque corrobora el límite de la física óptica en la "Sombra Nube", que requerirá hibridación con datos topográficos [cite: 1].

8.7. Empaquetado y Despliegue Estático (Fase 6)

La transición a un entorno *Cloud-Native* se orquestó mediante un script de Procesamiento Efímero (*Serverless*) [cite: 1]. El sistema interroga la API, descarga los gránulos en memoria volátil, infiere las máscaras y destruye los archivos de entrada, proyectando los resultados finales en formatos estáticos de alta disponibilidad para consumo web [cite: 1].

9. Discusión y Análisis Crítico

El desarrollo empírico ha expuesto las deficiencias arquitectónicas que limitan la solución [cite: 1]:

1. **La barrera de la física óptica:** Al descartar la topografía en favor del *Green Computing*, el modelo es incapaz de discriminar sombras orográficas de sombras de nubes basándose solo en fotones[cite: 1].
2. **Escalabilidad nula del Ground Truth:** Forjar un dataset auditado dependió exhaustivamente de intervención humana manual, un modelo imposible de escalar globalmente sin IA generativa[cite: 1].
3. **Omisión de Índices Espectrales Clave:** La ausencia del Índice Diferencial de Agua Normalizado (NDWI) obligó a solventar confusiones de masas hídricas mediante etiquetado manual exhaustivo[cite: 1].
4. **Limitaciones de VRAM (OOM):** La inyección de tensores densos provocó inestabilidades que forzaron la reducción del tamaño del lote (*Batch Size*), ralentizando la convergencia[cite: 1].

10. Conclusiones y Futuras Líneas de Investigación

Como síntesis técnica, se establecen las siguientes directrices evolutivas[cite: 1]:

1. **Fusión Multimodal y Topográfica:** Inyectar el Modelo de Elevaciones (DEM) directamente en la red convolucional erradicará el fallo de las sombras topográficas[cite: 1].
2. **Despliegue Serverless con Rust:** Reescribir el backend de inferencia on-the-fly para un rendimiento y consumo de memoria optimizado en la nube[cite: 1].
3. **Auditoría mediante Modelos Visuales (VLM):** Emplear LLaVA o PaliGemma para detectar inconsistencias en el *Ground Truth* de manera automática[cite: 1].
4. **Ampliación Semántica:** Escalar el modelo para monitorizar cicatrices de incendios y estrés hídrico[cite: 1].

11. Referencias Bibliográficas

- Baetens, L., Desjardins, C., & Hagolle, O. (2019). Validation of Copernicus Sentinel-2 Cloud Masks Obtained from MAJA, Sen2Cor, and FMask Processors... *Remote Sensing*, 11(4), 433[cite: 1].
- European Space Agency [ESA]. (2026). Copernicus Open Access Hub - Sentinel-2 Data Access[cite: 1].
- Hollstein, A., Segl, K., Guanter, L., Kneubühler, M., & Legleiter, C. (2016). Ready-to-Use Methods for the Detection of Clouds... *Remote Sensing*, 8(8), 666[cite: 1].
- Institut Cartogràfic i Geològic de Catalunya [ICGC]. (2026). Models d'Elevacions del Terreny de Catalunya[cite: 1].
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *MICCAI 2015*, 234-241[cite: 1].
- Wieland, M., Li, Y., & Martinis, S. (2019). Multi-sensor cloud and cloud shadow segmentation with a convolutional neural network. *Remote Sensing of Environment*, 230, 111203[cite: 1].

Anexo I: Manual de Despliegue y Reproducibilidad

A. Configuración del Entorno Virtual

1. Creación del archivo local de variables de entorno `.env` conteniendo las credenciales OAuth de *Copernicus Data Space Ecosystem* (`CDSE_USERNAME`, `CDSE_PASSWORD`)[cite: 1].
2. Despliegue del entorno virtual Python e instalación de dependencias `pip install -r requirements.txt` [cite: 1].

B. Orquestación de Ingesta ETL Para ejecutar la descarga asíncrona de los lotes de Entrenamiento y Test[cite: 1]:

- Entrenamiento: Ejecución del script `001_download_training.py` [cite: 1].
- Test: Ejecución del script `002_download_test.py` [cite: 1]. Estos módulos procesarán los listados `.csv` , generarán los modelos de color a 20m y construirán los lienzos GeoTIFF multicapa (`_SCL_GIMP.tif`) [cite: 1].

C. Procedimiento de Edición Visual (GIMP)

1. Importar el archivo `_SCL_GIMP.tif` al entorno gráfico, manteniendo la estructura de capas (Máscara, Color Falso Nieve y Color Real)[cite: 1].
2. Ajustar opacidades para la evaluación visual y emplear la herramienta Lápiz (sin interpolación ni antialiasing) sobre la capa superior para enmendar las áreas de clasificación errónea[cite: 1].
3. Sobrescribir el fichero gráfico y ejecutar `003_decode_gimp_edits.py` para restaurar la integridad topológica y georreferencial del tensor matemático[cite: 1].